

Генератор русских диминутивов

Основная идея проекта

Веб-приложение для автоматического поиска диминутивов русского языка на основе результатов лингвистического исследования и языковой модели GPT.

Пользователь вводит существительное, после чего система формирует список возможных диминутивных форм и отображает их характеристики.

Уникальность проекта

Проект сочетает несколько подходов:

- использование корпуса диминутивов, собранного в рамках лингвистического исследования;
- генерацию кандидатов с помощью GPT;
- проверку словарности форм через `ru morphology2`;
- ранжирование результатов по степени достоверности.

Такой подход позволяет уменьшить количество галлюцинаций языковой модели и получать результаты, близкие к реально существующим формам русского языка.

Целевая аудитория

Проект может быть полезен:

- школьникам и студентам филологических направлений;
 - преподавателям русского языка;
 - исследователям словообразования;
 - разработчикам образовательных сервисов;
 - всем интересующимся русской морфологией.
-

Особенности реализации

Основные возможности

- ввод слова через веб-интерфейс;
- поиск диминутивов на основе корпуса исследования;
- генерация дополнительных форм с помощью GPT;
- определение суффиксов найденных слов;
- проверка словарности через `ru morphology2`;
- ранжирование результатов по системе баллов;
- отображение результатов в виде таблицы.

Возможные улучшения

- расширение корпуса исследования;
 - подключение дополнительных словарей;
 - автоматическое определение эмоциональной окраски;
 - экспорт результатов в CSV и Excel;
 - создание REST API;
 - визуализация статистики продуктивности суффиксов.
-

Используемые технологии

- Flask
 - LangChain
 - GPT-4o-mini
 - pymorphy2
 - python-docx
 - gunicorn
-

Технические особенности

Источник данных

Проект использует файл:

school_research.docx

Документ содержит результаты исследования диминутивных форм русского языка и используется как локальный корпус данных.

Обработка данных

1. Пользователь вводит существительное.
2. Из корпуса извлекаются найденные формы.
3. GPT генерирует дополнительные варианты.
4. Для каждой формы определяется:
5. суффикс;
6. словарность;
7. источник получения.
8. Формы ранжируются по степени достоверности.
9. Результаты отображаются пользователю.

Техники промптинга

Для уменьшения количества галлюцинаций используются:

- примеры диминутивов из исследования;
- статистика продуктивности суффиксов;
- ограничения на генерацию искусственных форм;
- требование сохранять основу исходного слова;
- генерация только реально употребляемых форм русского языка.

Используемая модель

```
gpt-4o-mini
```

Хранение данных

На текущем этапе отдельная база данных не используется.

Все исследовательские данные хранятся в файле:

```
school_research.docx
```

Установка и запуск

```
pip install -r requirements.txt  
python app.py
```

После запуска приложение будет доступно по адресу:

```
http://127.0.0.1:5000
```

Структура проекта

```
project/  
├─ app.py  
├─ school_research.docx  
├─ templates/  
│   └─ index.html  
├─ requirements.txt  
└─ README.md
```

Автор

Юлия Маракасова

Учебный проект по применению технологий искусственного интеллекта для решения задач русской морфологии и словообразования.